

תרגיל כיתה 4 – העתקת מאפיינים

שאלה 1

נתונות הדוגמאות הבאות של עצמים שמיוצגים עם שני מאפיינים :

$$\mathbf{x}_1 = \begin{bmatrix} -2 \\ 0 \end{bmatrix} \quad \mathbf{x}_2 = \begin{bmatrix} -1 \\ 2 \end{bmatrix} \quad \mathbf{x}_3 = \begin{bmatrix} 0 \\ 3 \end{bmatrix} \quad \mathbf{x}_4 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad \mathbf{x}_5 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \mathbf{x}_6 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

(א) חשב את העתקת PCA עבור הנתונים הבאים :

(ב) העתק את הנתונים לכאלה עם מאפיין יחיד. מהי השגיאה הריבית הממוצעת ?

פתרון שאלה 1

נסמן ב- \mathbf{m}_x את וקטור התוחלת של הנתונים, וב- \mathbf{C}_x מטריצת הקווריאנס שלהם.

$$\mathbf{m}_x = \frac{1}{M} \sum_{k=1}^M \mathbf{x}_k$$

$$\mathbf{C}_x = \frac{1}{M} \sum_{k=1}^M \mathbf{x}_k \mathbf{x}_k^T - \mathbf{m}_x \mathbf{m}_x^T$$

$$\mathbf{m}_x = \frac{1}{6} \begin{pmatrix} -2 - 1 + 0 + 0 + 1 + 2 \\ 0 + 2 + 3 + 1 + 2 + 4 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

$$\mathbf{C}_x = \frac{1}{6} \begin{pmatrix} 4 + 1 + 0 + 0 + 1 + 4 & 0 - 2 + 0 + 0 + 2 + 8 \\ 0 - 2 + 0 + 0 + 2 + 8 & 0 + 4 + 9 + 1 + 4 + 16 \end{pmatrix} - \begin{pmatrix} 0 & 0 \\ 0 & 4 \end{pmatrix} = \begin{pmatrix} 5/3 & 4/3 \\ 4/3 & 5/3 \end{pmatrix}$$

העתקת PCA היא אז :

$$\mathbf{y} = \mathbf{A}(\mathbf{x} - \mathbf{m}_x)$$

כאשר השורות של המטריצה \mathbf{A} הן הוקטורים העצמיים של מטריצת הקווריאנס. הוקטורים העצמיים של מטריצת הקווריאנס מחושבים לפי :

$$\mathbf{C}_x \mathbf{e}_i = \lambda_i \mathbf{e}_i \quad \Leftrightarrow \quad \begin{pmatrix} 5/3 & 4/3 \\ 4/3 & 5/3 \end{pmatrix} \begin{pmatrix} e_{i1} \\ e_{i2} \end{pmatrix} = \lambda_i \begin{pmatrix} e_{i1} \\ e_{i2} \end{pmatrix}$$

והערכים העצמיים מחושבים מתוך

$$\det |\mathbf{C}_x - \lambda \mathbf{I}| = 0,$$

$$\begin{vmatrix} 5/3 - \lambda & 4/3 \\ 4/3 & 5/3 - \lambda \end{vmatrix} = \left(\frac{5}{3}\right)^2 - 2 \cdot \frac{5}{3} \cdot \lambda + \lambda^2 - \left(\frac{4}{3}\right)^2 = \lambda^2 - \frac{10}{3} \lambda + 1 = 0 \Rightarrow \lambda_1 = 3 \text{ and } \lambda_2 = 1/3.$$

והוקטורים העצמיים המתאימים הם :

$$\Rightarrow \quad \mathbf{e}_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

ומטריצת ההעתקה של PCA היא

$$\mathbf{A} = \begin{pmatrix} \mathbf{e}_1^T \\ \mathbf{e}_2^T \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

ב) ההעתקה משני מאפיינים למאפיין אחד היא על ידי שימוש בוקטור עצמי יחיד, זה שמתאים לערך העצמי הגבוה יותר:

$$A = e_1^T = (1/\sqrt{2} \quad 1/\sqrt{2})$$

השגיאה הריבועית הממוצעת היא אז:

$$\text{is } R = \lambda_2 = 1/3.$$

הערכים של המאפיין היחיד עבור הנתונים הם:

$$y_1 = A(x - m_x) = e_1^T(x_1 - m_x) = (1/\sqrt{2} \quad 1/\sqrt{2}) \begin{pmatrix} -2-0 \\ 0-2 \end{pmatrix} = -2\sqrt{2}$$

$$y_2 = -\sqrt{2}/2, y_3 = \sqrt{2}/2, y_4 = -\sqrt{2}/2, y_5 = \sqrt{2}/2, y_6 = 2\sqrt{2}.$$

(א) התפלגות של וקטורי המאפיינים גלגלי הקולבול משותפת עם:

$$\mu_i = \frac{1}{n_i} \sum_{x \in c_i} x \quad i=1, 2$$

$$\mu_1^T = (0.4, 0.8) \quad \mu_2^T = (-0.6, -1) \quad \text{ומתקבל}$$

(ב) שם ניקח מרכזת הקואריאנס הוא עם:

$$\hat{\Sigma}_i = \frac{1}{n_i} \sum_{x \in c_i} (x - \mu_i)(x - \mu_i)^T \quad i=1, 2$$

מאחר שמרכזת הקואריאנס זהה גלגלי הקולבול, נפרק אותה בממוצע של מרכזת הקואריאנס:

$$\hat{\Sigma} = \frac{1}{2}(\hat{\Sigma}_1 + \hat{\Sigma}_2) = \frac{1}{20} \left[\sum_{x \in c_1} (x - \mu_1)(x - \mu_1)^T + \sum_{x \in c_2} (x - \mu_2)(x - \mu_2)^T \right]$$

$$\hat{\Sigma} = \begin{pmatrix} 0.54 & -0.35 \\ -0.35 & 0.68 \end{pmatrix}$$

(ג) מאחר שהערכים העצמיים של $\hat{\Sigma}$ הם λ_1 ו- λ_2 מתקבל:

$$\det(\hat{\Sigma} - \lambda I) = 0 = \begin{vmatrix} 0.54 - \lambda & -0.35 \\ -0.35 & 0.68 - \lambda \end{vmatrix}$$

$$(0.54 - \lambda)(0.68 - \lambda) - 0.35^2 = 0 \quad \text{או}$$

$$\lambda_1 = 0.967 \quad \lambda_2 = 0.253$$

(3) חזקת הערכים העצמיים של A היא $\lambda_1 = 0.431$ ו- $\lambda_2 = 0.369$

$$\sum x_i a_i = \lambda_i a_i$$

עבור $\lambda_1 = 0.431$ נמצא את a_1

$$(\hat{\Sigma}_x - \lambda_1 I) a_1 = 0$$

$$\begin{pmatrix} 0.54 - \lambda_1 & -0.35 \\ -0.35 & 0.68 - \lambda_1 \end{pmatrix} \begin{pmatrix} a_{11} \\ a_{12} \end{pmatrix} = 0$$

$$\begin{cases} -0.427 a_{11} - 0.35 a_{12} = 0 \\ -0.35 a_{11} - 0.287 a_{12} = 0 \end{cases}$$

יש להשתמש בהנחה $a_{12} = 1$ כדי למצוא את a_{11}

אם $a_{12} = 1$ נמצא a_{11} מהמשווא הראשונה

$$a_{11} = 0.35 / -0.427 = -0.82$$

$$a_1^T = (-0.82, 1)$$

נורמל

הערכים העצמיים של A הם $\lambda_1 = 0.431$ ו- $\lambda_2 = 0.369$

אם a_1^T הוא

העצמי של A עם הערך $\lambda_2 = 0.369$ נמצא את a_2

$$a_2 = (1, 0.82)^T$$

אם נניח, מתקבל הערך a_2 של A

$$a_1^T = (-0.82, 1)^T / (1 + 0.82^2)^{1/2} = (-0.634, 0.7733)^T$$

$$a_2^T = (1, 0.82)^T / (1 + 0.82^2)^{1/2} = (0.7733, 0.634)^T$$

הוקדוים הוצגוים שיתקדו הם אורטונורמליים, כפי שנגזר
 במקרה של הריבוע סימטרי - $(\hat{\Sigma}_x)$ כלומר:

$$\underline{a}_1^T \cdot \underline{a}_2 = 0$$

הריבוע החד-מקרה, זו למעשה אוקט המאפיינת בתנן, לוקח
 מסך קולציה (אמאסיין) מסוי קולציה:

$$A = \begin{pmatrix} \underline{a}_1 & \underline{a}_2 \end{pmatrix} = \begin{pmatrix} -0.634 & 0.7733 \\ 0.7733 & 0.634 \end{pmatrix}$$

(ה) אפסכ פהכאול פרייב-הקוויאנס של הוקטור הוודס \neq
 היא אלכסונל-קשת, אזכים. דברך הנאסוה נציג דדילא.

$$\Sigma_y = A \Sigma_x A^T$$

$$\begin{aligned} \Sigma_y &= \begin{pmatrix} -0.634 & 0.7733 \\ 0.7733 & 0.634 \end{pmatrix} \begin{pmatrix} 0.54 & -0.35 \\ -0.35 & 0.68 \end{pmatrix} \begin{pmatrix} -0.634 & 0.7733 \\ 0.7733 & 0.634 \end{pmatrix} = \\ &= \begin{pmatrix} 0.967 & 0 \\ 0 & 0.253 \end{pmatrix} = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} = \begin{pmatrix} \sigma_{y_1}^2 & 0 \\ 0 & \sigma_{y_2}^2 \end{pmatrix} \end{aligned}$$

כלומר, השולל של משפין, y היא, λ ושל מאפין y_2 היא λ_2 .

הצגה דומה מתקדלת גם פהכא הוצגה מאפיה.

משולל הוקטור/זקן עצמי היא

$$\Sigma_x \underline{a}_i = \lambda_i \underline{a}_i$$

ואם מצרפים את המשולל של Σ מתקדל

$$\Sigma_x A = A \Lambda$$

כאשר Λ הוא מטריצה אורתוגונלית עם ערכי λ_i על האלכסון.

אחר כך A^{-1} של P היא עדיין מתקן

$$A^{-1} \Sigma_x A = A^{-1} A \Lambda = \Lambda$$

מאחר של A אורתוגונליות, מתקיים $A^T = A^{-1}$

$$\Sigma_y = A^T \Sigma_x A = \Lambda$$

ובמקרה: המאפיינים של וקטור המאפיינים החד y הם מסתו קולציה, והשוויון שלהם הן הצורה החדשה של מיליציה הקולציה Σ_x .

(1) העלמה של וקטורי הדומיננטיות \underline{a}_1 מתקבלת ע"י

$$y_1 = \underline{a}_1^T \underline{x} = a_{11} x_1 + a_{12} x_2 = -0.634 x_1 + 0.7733 x_2$$

אכאן צומת, העלמה של \underline{a}_2 של הדומיננטיות מתקבלת ע"י


$$y_2 = \underline{a}_2^T \underline{x} = a_{21} x_1 + a_{22} x_2 = 0.7733 x_1 + 0.634 x_2$$

הקצוות היחידים מתקבלים ע"י y_1 :

$$\{1.09, 1.5466, 0.1393, 0.07, -1.02\}$$

הקצוות השניה ע"י y_2 הם:

$$\{1.268, -0.07, 0.526, -1.09, -1.5466\}$$




x - קצוות
 0 - קצוות

הקצוזה הסטטיסטית ערכי y_2 הם :

$$\{0.2474, 1.268, 1.407, 0.704, 0.456\}$$

הקצוזה הסטטיסטית ערכי y_2 הם :

$$\{-1.5466, -0.704, -1.724, -0.2474, -1.268\}$$



x - קצוזה אחת

o - קצוזה שנייה

בטבלה של פילוף הסטטיסטי של מאפיין y_1 אין הסכמה בין הקצוזה

למחלקה אחת, הסכמה בין הקצוזה ערכי מאפיין y_2 וזה,

תוצאה זו עולה בקנה אחד עם ההנחות הכלליות : קוורטים

המאפיינים עם הערכים (y_1, y_2) הקצוזה אחת.

(3) יש לבדוק במאפיין y_2 כפי שצוין על הסכמה אחת בין הקצוזה

יש לבדוק במאפיין y_1 כפי שצוין על הסכמה אחת בין הקצוזה

למחלקה אחת.

(4) נמצא הסכמה ערכי מאפיין y_1 וזה קצוזה אחת

$$\chi^2 = \frac{(\mu_1 - \mu_2)^2}{\sigma_1^2 + \sigma_2^2}$$

μ_1 ו- μ_2 הן הממוצעים של המאפיין בשתי הקצוזה, σ_1^2 ו- σ_2^2

הן השונות של שתי הקצוזה.

2.50. נ. מוקדם פחות מזה המסופים המוקדים - x_1 -
 נ. שנים מזה פחות מזה יותר נ. מוקדים.

עבור המסופים x_1 :

$$\hat{\mu}_1 = \frac{-0.5 + 0 + 1 + 0.5 + 1}{5} = 0.4$$

$$\hat{\mu}_2 = \frac{-1.2 - 0.5 - 1 + 0.5 + 0}{5} = -0.6$$

$$\hat{\sigma}_1^2 = \frac{1}{5} \sum (x_1 - 0.4)^2 = \frac{0.9^2 + 0.4^2 + 0.6^2 + 0.1^2 + 0.6^2}{5} = 0.34$$

$$\hat{\sigma}_2^2 = \frac{1}{5} \sum (x_1 + 0.6)^2 = \frac{1.4^2 + 0.1^2 + 0.4^2 + 0.1^2 + 0.6^2}{5} = 0.74$$

$$J_{x_1} = \frac{(0.4 + 0.6)^2}{0.34 + 0.74} = \frac{1}{1.08}$$

למסופים מזה עדיף מסופים x_2 :

$$\hat{\mu}_1 = 0.8 \quad \hat{\mu}_2 = -1$$

$$\hat{\sigma}_1^2 = 0.86 \quad \hat{\sigma}_2^2 = 0.5$$

$$J_{x_2} = \frac{(0.8 + 1)^2}{0.86 + 0.5} = \frac{3.24}{1.16} > J_{x_1}$$

מזה הפחות מזה יותר עדיף מסופים x_2 , ולכן אם נרצה פחות
 באותו מסופים המסופים, נבחר x_2 .

(ט) העתקת MDA משני מאפיינים למאפיין יחיד נותנת את ההפרדה הטובה ביותר:

$$J(\underline{w}) = \frac{|m_1 - m_2|^2}{\sigma_1^2 + \sigma_2^2} = \frac{\underline{w}^T S_B \underline{w}}{\underline{w}^T S_W \underline{w}}$$

וההעתקה \underline{w} היא הוקטור העצמי של המטריצה $S_W^{-1} S_B$ כאשר

$$S_W = \Sigma_1 + \Sigma_2$$

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

התוצאה של וקטורי המאפיינים בשתי הקטגוריות ממוצעת.

$$\mu_i = \frac{1}{n_i} \sum_{x \in c_i} x \quad i=1, 2$$

$$\mu_1^T = (0.4, 0.8) \quad \mu_2^T = (-0.6, -1) \quad \text{אחת קטג}$$

$$S_B = \begin{pmatrix} 1.0 \\ 1.8 \end{pmatrix} \begin{pmatrix} 1.0 & 1.8 \end{pmatrix} = \begin{pmatrix} 1.0 & 1.8 \\ 1.8 & 1.0 \end{pmatrix}$$

שם נלקח ממוצעת הקטגוריות, הנה

$$\hat{\Sigma}_i = \frac{1}{n_i} \sum_{x \in c_i} (x - \mu_i)(x - \mu_i)^T \quad i=1, 2$$

$$\hat{\Sigma} = (\hat{\Sigma}_1 + \hat{\Sigma}_2) = \frac{1}{5} \left[\sum_{x \in c_1} (x - \mu_1)(x - \mu_1)^T + \sum_{x \in c_2} (x - \mu_2)(x - \mu_2)^T \right]$$

$$\hat{\Sigma} = \begin{pmatrix} 0.54 & -0.35 \\ -0.35 & 0.68 \end{pmatrix} * 2$$

$$S_W = \hat{\Sigma} = \begin{pmatrix} 1.08 & -0.7 \\ -0.7 & 1.36 \end{pmatrix} \quad S_W^{-1} = \begin{pmatrix} 1.3895 & 0.7152 \\ 0.7152 & 1.1034 \end{pmatrix}$$

$$S_W^{-1} S_B = \begin{pmatrix} 2.6767 & 3.2162 \\ 2.7013 & 2.3907 \end{pmatrix}$$

$$\bar{W} = S_W^{-1} (\bar{\mu}_1 - \bar{\mu}_2) = \begin{pmatrix} 1.3895 & 0.7152 \\ 0.7152 & 1.1034 \end{pmatrix} \begin{pmatrix} 1.0 \\ 1.8 \end{pmatrix} = \begin{pmatrix} 2.6767 \\ 2.7013 \end{pmatrix}$$

וההעתקה היא: $y = \bar{w}^T \bar{x} = 2.6767x_1 + 2.7013x_2$

ערכי המאפיין החדש y בקבוצה 1 הם:

$$y = \{1.3629 \quad 5.4026 \quad 5.3780 \quad 2.6890 \quad 1.3260\}$$

ערכי המאפיין החדש y בקבוצה 2 הם:

$$y = \{-5.3534 \quad -2.6890 \quad -6.7287 \quad -1.3629 \quad -5.4026\}$$

ניתן לראות שהמאפיין היחיד y הוא בעל ערכים שונים באופן בולט בשתי הקבוצות ללא חפיפה ביניהן