

ללמד את המחשב ללמוד: הבחנה בין כלבים לחתולים



A simple example (toy task)

Reference: Machine learning refined, Watt, Borhani & Katsaggelos, 2016

אימון מודל

- לימוד המחשב איך להבחין בין כלבים לחתולים --> בעייה גאומטרית: מציאת קו או **מודל ליניארי** (line) – הפרדה בין כלבים לחתולים ב**מרחב התכונות** (feature space)
- מציאת השיפוע (slope) והחיתוך עם ציר ה-y (intercept).
- **אימון המודל** – מציאת הפרמטרים של המודל בהינתן **קבוצת האימון** (training set), (באמצעות כלים של אופטימיזציה נומרית).



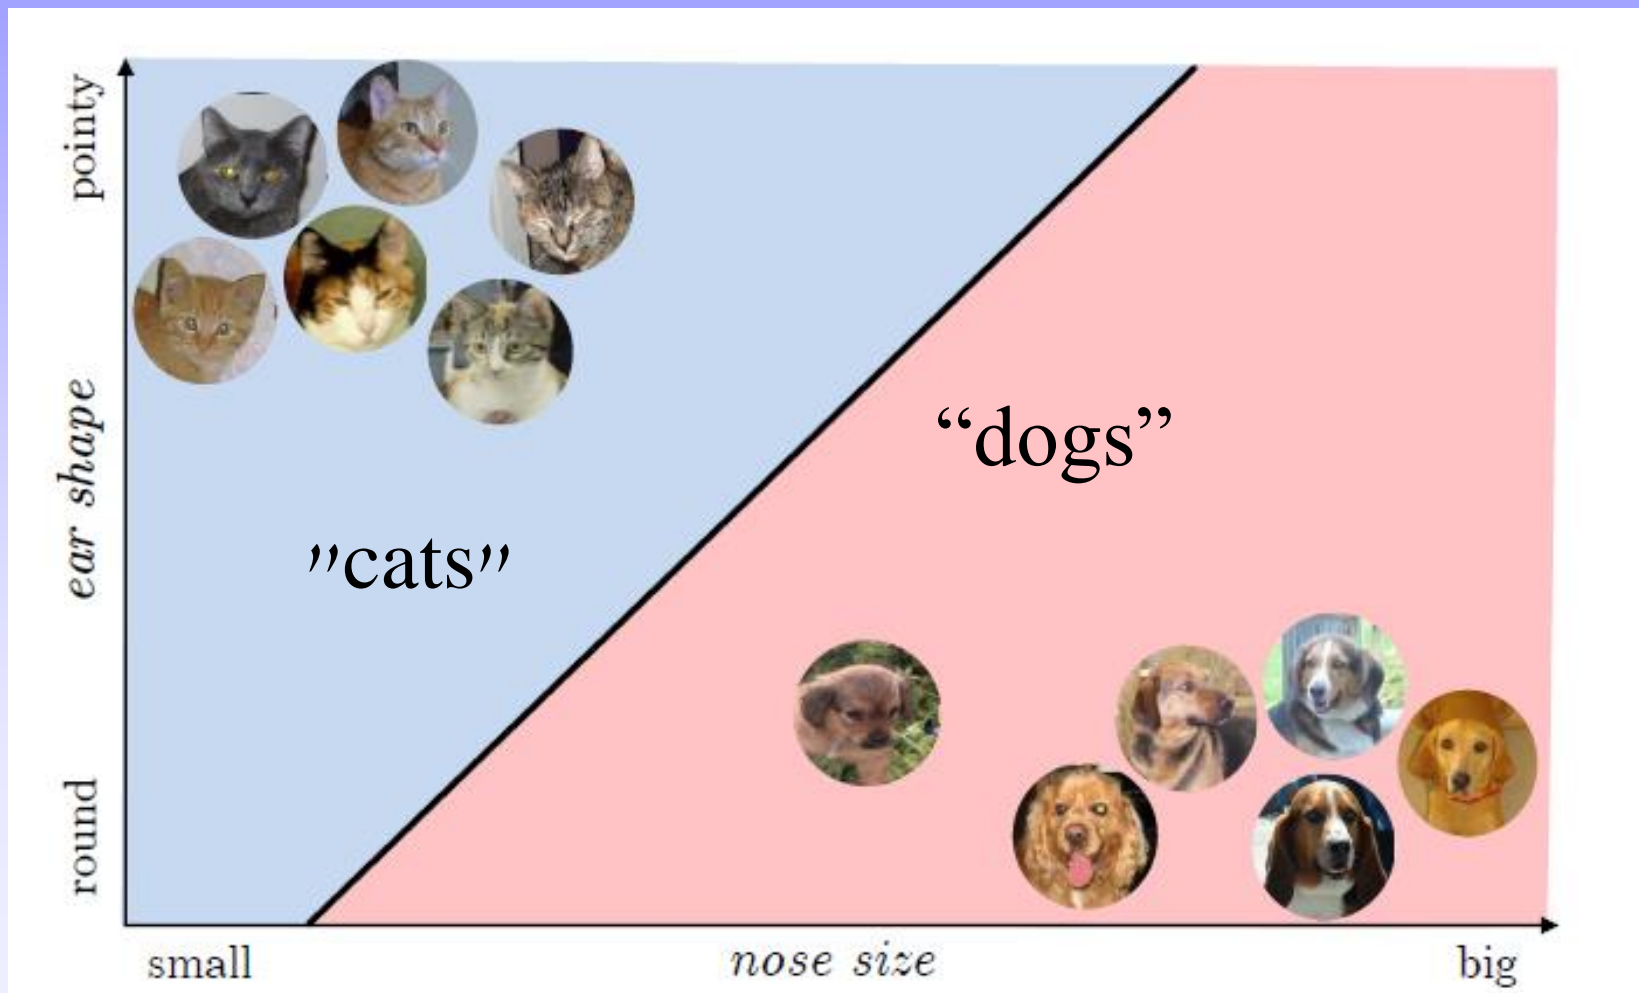
אימון מודל



Trained linear model

מודל לאחר אימון

How to classify future images?




בחינת מודל

- דוגמאות חדשות – קבוצת דוגמאות מבחן
- (testing set of data)



זיהוי תמונות המבחן


Feature extraction, and check which side of the line the feature representation falls on



- One misidentification (Boston terrier).
- How would we improve our learner?

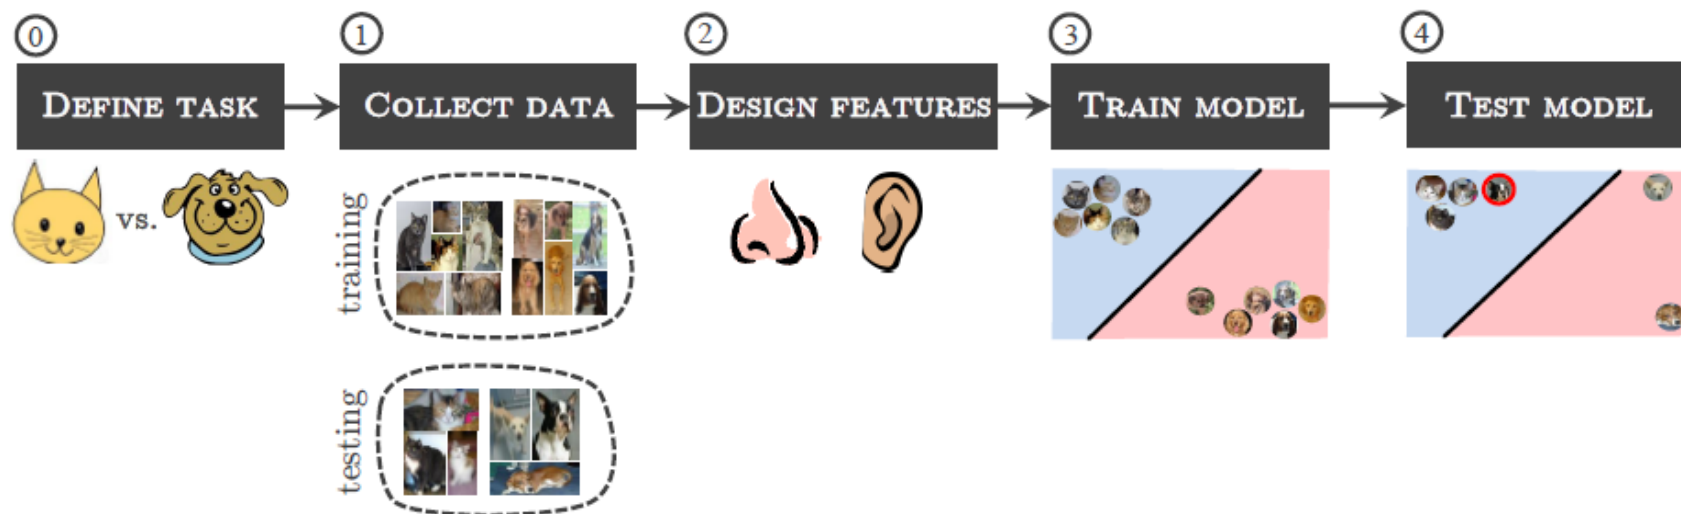
שיפור הלמידה

- Collect more data
- More diverse training set
- Designing more discriminating features (eye color, tail shape, others).
- Train a new model using the designed features
- Test again in the same manner



הצגה סכימטית של תהליך הלימוד

- של בעיית מערכת לומדת (Machine Learning) אופיינית
- הצעדים הנדרשים לפתרון של בעיות למידה חישובית אופייניות



הצגה סכימטית של תהליך הלימוד

- ① **Define the problem.** What is the task we want to teach a computer to do?
- ① **Collect data.** Gather data for training and testing sets. The larger and more diverse the data the better.
- ② **Design features.** What kind of features best describes the data?
- ③ **Train the model.** Tune the parameters of an appropriate model on the training data using numerical optimization.
- ④ **Test the model.** Evaluate the performance of the trained model on the testing data. If the results of this evaluation are poor, re-think the particular features used and gather more data if possible.

Predictive learning problems בעיות למידה

- בעיית הרגרסיה (regression)
- בעיית הסווג (classification)





בעיות חיזוי: רגרסיה

דוגמא : חיזוי מחיר של מניה לפני הנפקה.

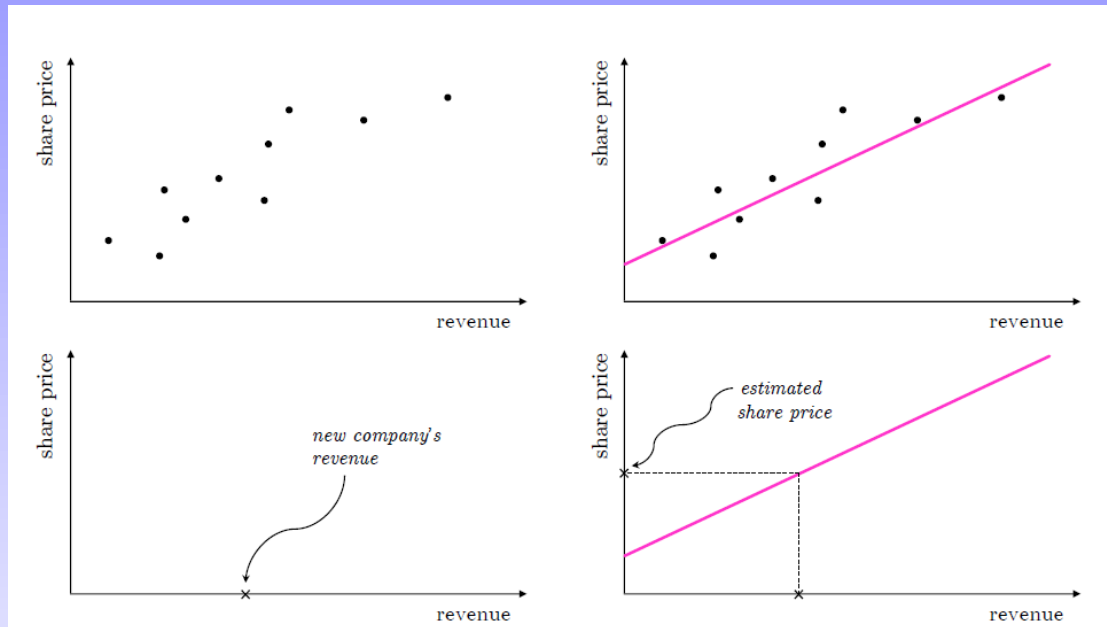
בהתאם לסכימה של תהליך הלימוד :

- נבצע איסוף נתונים – מחירי מניות של חברות שונות (עדיפות לחברות הפעילות באותו תחום).
- השלב הבא : בחירת ומיצוי תכונה או תכונות הרלבנטיות למשימה
- תכונה אפשרית אחת : ההכנסה השנתית הממוצעת (תכונות פוטנציאליות אחרות : השווי הכולל של החברה, מספר המועסקים, מספר שנות פעילות וכו').
- כדי לקשר בין מחיר המניה להכנסה השנתית הממוצעת – משתמשים בנתוני האימון לאמן מודל ליניארי או קו רגרסיה.

בעיות חיזוי: רגרסיה




בעיות חיזוי: רגרסיה



באמצעות **קו הרגרסיה** אפשר לחזות מה יהיה החוב בשנים הבאות.
משימה זו של התאמת מודל על-פי קבוצת נתוני אימון כך שאפשר
יהיה לבצע חיזויים עבור משתנה רציף נקראת **רגרסיה** (regression)

רגרסיה: דוגמא 1

בעיית החוב של אזרחי ארה"ב עבור לימודים



- רואים כי החוב גדל פי 3 במהלך השנים 2006-2014.
- סכום של טריליון דולר בסוף 2014.
- קו הרגרסיה (בסגול) מתאים די טוב לנתונים.
- מה המשמעות של השיפוע החיובי?

חוב עבור שכר לימוד, מעונות ומחיה, נמדד כל רבעון


Joelle Scally, and Wilbert van der Klaauw. Federal Reserve Bank of New York Staff Reports, no. 668. April 2014.

רגרסיה: דוגמא 2

האם אפשר לחזות כיום מה יהיו ההכנסות של סרט קולנוע שיצא למסכים בעוד מספר חודשים?

נמצא כי אפשר להשתמש ברגרסיה לינארית כדי לחזות תוך שימוש ב dataset המכיל לדוגמא:

- מספר חיפושי אינטרנט של קדימונים (trailers) בתקופה מסויימת
 - כמות הדיונים ברשתות חברתיות באותה תקופה
- לצורך חיזוי ההכנסה של סרט חדש.



רגרסיה – דוגמא 3


קישור בין גנים למאפיינים כמותיים

Genome Wide Association (GWA)

- מטרת מחקרי GWA – הבנת הקשרים בין עשרות אלפי סמנים (markers) גנטיים לאורך גנום אנושי של פרטים רבים לבין מחלות כמו סכרת, פרקינסון, או בעיות אחרות.
- המחקרים נעשים בתקווה למצוא ריפוי מכוון גנים (gene-targeted therapies), לבעיות כמו אלה הנגרמות על-ידי גן בודד.
- משתמשים ברגרסיה ככלי להבנת קשרי הגומלין המורכבים בין סמנים גנטיים (תכונות) למאפיינים כמותיים רציפים (רמת הסוכר בדם)

רגרסיה – דוגמא 3

קישור בין גנים למאפיינים כמותיים




Genome Wide Association (GWA)

- תיאור רעיוני של מחקר GWA המשתמש ברגרסיה בו מנסים לקשר בין תכונה כמותית (רמת הסוכר, לחץ דם) לבין מיקומים גנומיים ספיציפיים.

בעיית הסיווג (Classification)

- ההבדל בין רגרסיה לסווג – ערכי משתנה התוצאה רציפים ברגרסיה ובדידים (מחלקות) בבעיית הסווג.
- Discrete values or **classes**
- דוגמא לבעיות סווג : זיהוי עצמים בתמונה **object recognition**



בעיית הסיווג (object recognition)

Muffin or chihuahua?



בעיית הסיווג (object recognition)

Kitten or vanilla ice cream?



בעיית הסיווג (object recognition)

Dalmatian or ice cream?



בעיית הסיווג (object recognition)

Canine or Cuisine?



בעיית הסיווג (object recognition)

Barn owl or apple?



בעיית הסיווג (Classification)


- זיהוי אוטומטי של ספרות בכתב יד של מיקוד
- זיהוי שלטי דרכים למערכות נהיגה אוטומטיות.
- זיהוי תמונות של כלבים/חתולים



בעיית הסיווג (Classification)

- בעיות זיהוי נוספות :

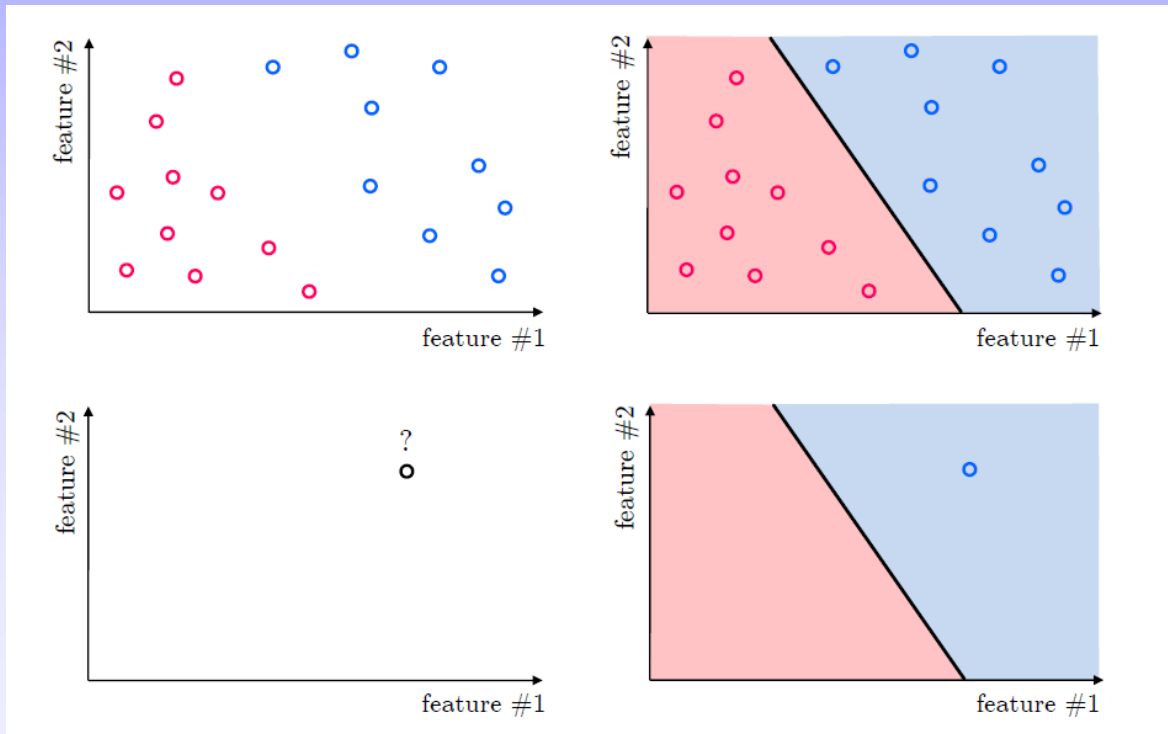
- זיהוי דיבור
- זיהוי דובר
- זיהוי מצב הרוח העיקרי בשיח של רשתות חברתיות עבור מוצר או שרות מסויים
- זיהוי מחוות יד (hand gesture) מתוך מספר סופי של מחוות לשליטה במכשיר



- זיהוי גנים (אזורים המקודדים חלבונים) לפי ה-DNA
- זיהוי מצבים או בעיות קוגניטיביות על-ידי מבחנים (זיהוי ADHD)

בעיית הסיווג (Classification)

- באופן גאומטרי – דרך מקובלת לראות את בעיית הסיווג היא מציאת ישר (או מישור או על-מישור במרחב עם ממד גבוה) המפריד בין דוגמאות של שתי מחלקות (מודל מפריד עבור מספר גבוה יותר של מחלקות נציג בהמשך).
- לאחר האימון וקביעת המודל (הישר המפריד) מציאת הסוג של דוגמא חדשה תהיה בהתאם למיקום של הנקודה ביחס לישר (המישור או העל-מישור) המפריד.



A linear model or classifier for performing classification of a 2-d dataset

זיהוי עצמים (object detection)

- המטרה: זיהוי אוטומטי של אובייקטים בקבוצת תמונות או וידאו
דוגמאות פופולריות:
- זיהוי פנים בתמונה למטרות אירגוניות או למיקוד מצלמה,



זיהוי עצמים (object detection)

- זיהוי הולכי רגל עבור רכבים אוטונומיים

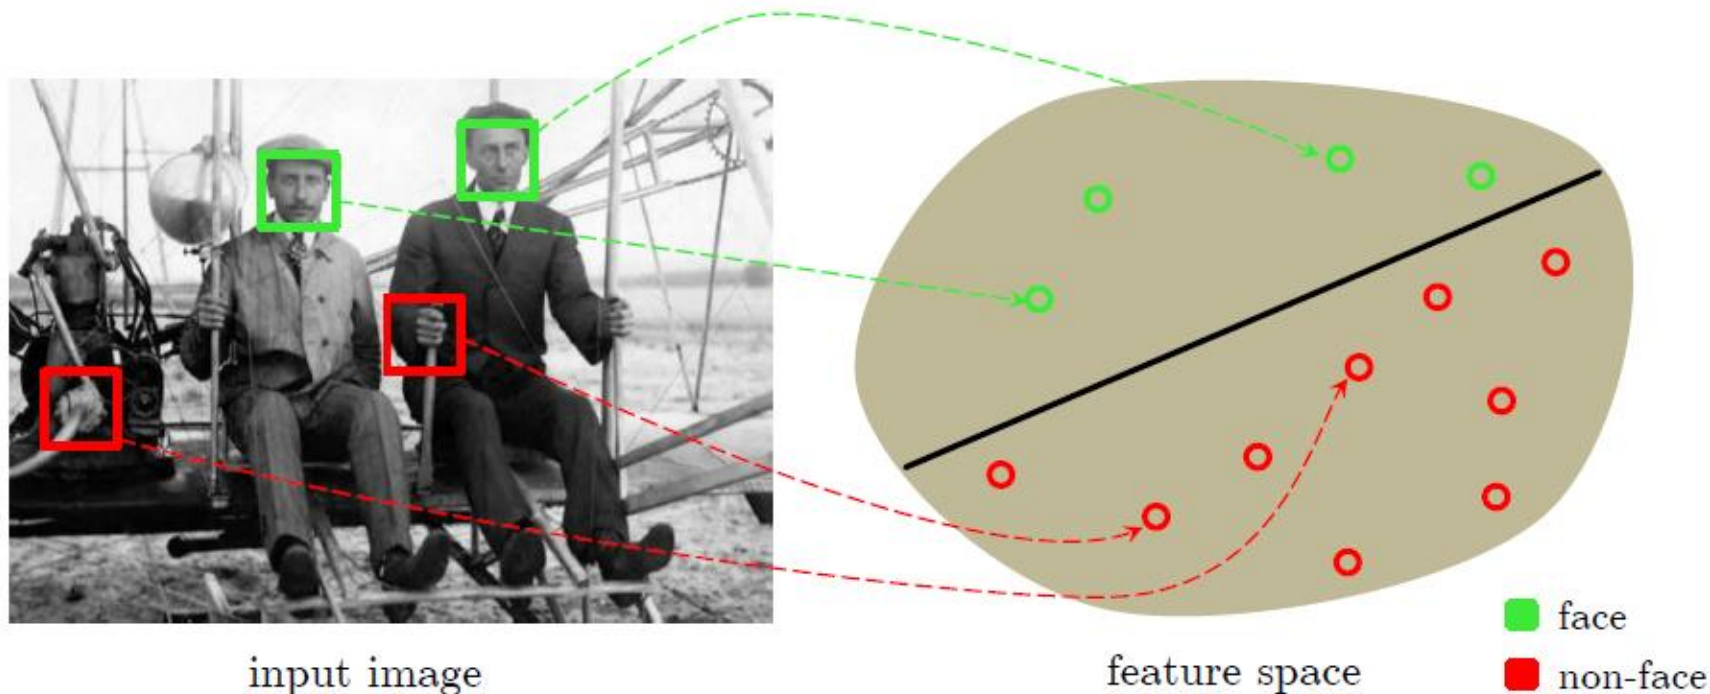


זיהוי עצמים (object detection)

- זיהוי רכיבים פגומים לבקרת איכות אוטומטית עבור תעשיית האלקטרוניקה.



זיהוי עצמים (object detection)




הצגת תמונה חדשה למסווג ליניארי (לאחר אימון עם דוגמאות ביניהן תמונות פנים ותמונות של עצמים אחרים).

בדרך כלל מזהים את הפנים על-ידי מעבר של חלון ריבועי העובר על כל התמונה וקביעת ההחלטה על-פי המיקום של הנקודה במרחב התכונות של המסווג.

Feature design


- תכונות הן המאפיינים המגדירים של קבוצת הנתונים המאפשרים למידה אופטימלית
- בחירה נכונה של תכונות חשובה ביותר לתפקוד של רגרסיה וסוג.
- הבנה רבה יותר של התופעות והתהליכים של ייצור הנתונים – מאפשרת למצות ולבחור תכונות טוב יותר או ללמד את המחשב לעשות זאת.
- במקרה הקיצוני הידע הזה מאפשר לבחור תכונות המאפשרות למידה מושלמת.
- בדרך כלל – ידע מוגבל על קבוצת הנתונים.

הניסוי של גלילאו – תאוצה קבועה



- מה משך הזמן הנדרש לכדור להתגלגל במורד המישור המשופע בשל כוח הגרביטציה, וכן עבור רבע, מחצית, שני שליש ושלושה רבעים של המרחק.
- ההשערה: קיים קשר ליניארי בין המרחק שהגוף עובר לזמן בריבוע

הניסוי של גלילאו – תאוצה קבועה



- שחזור מודרני של הניסוי : כל נקודה בגרף היא ממוצע של 30 ניסויים.
- השימוש בתכונת הזמן בריבוע מאפשרת להראות את הקשר הלינארי של הנתונים, והתאמת רגרסיה לינארית כמעט מושלמת.

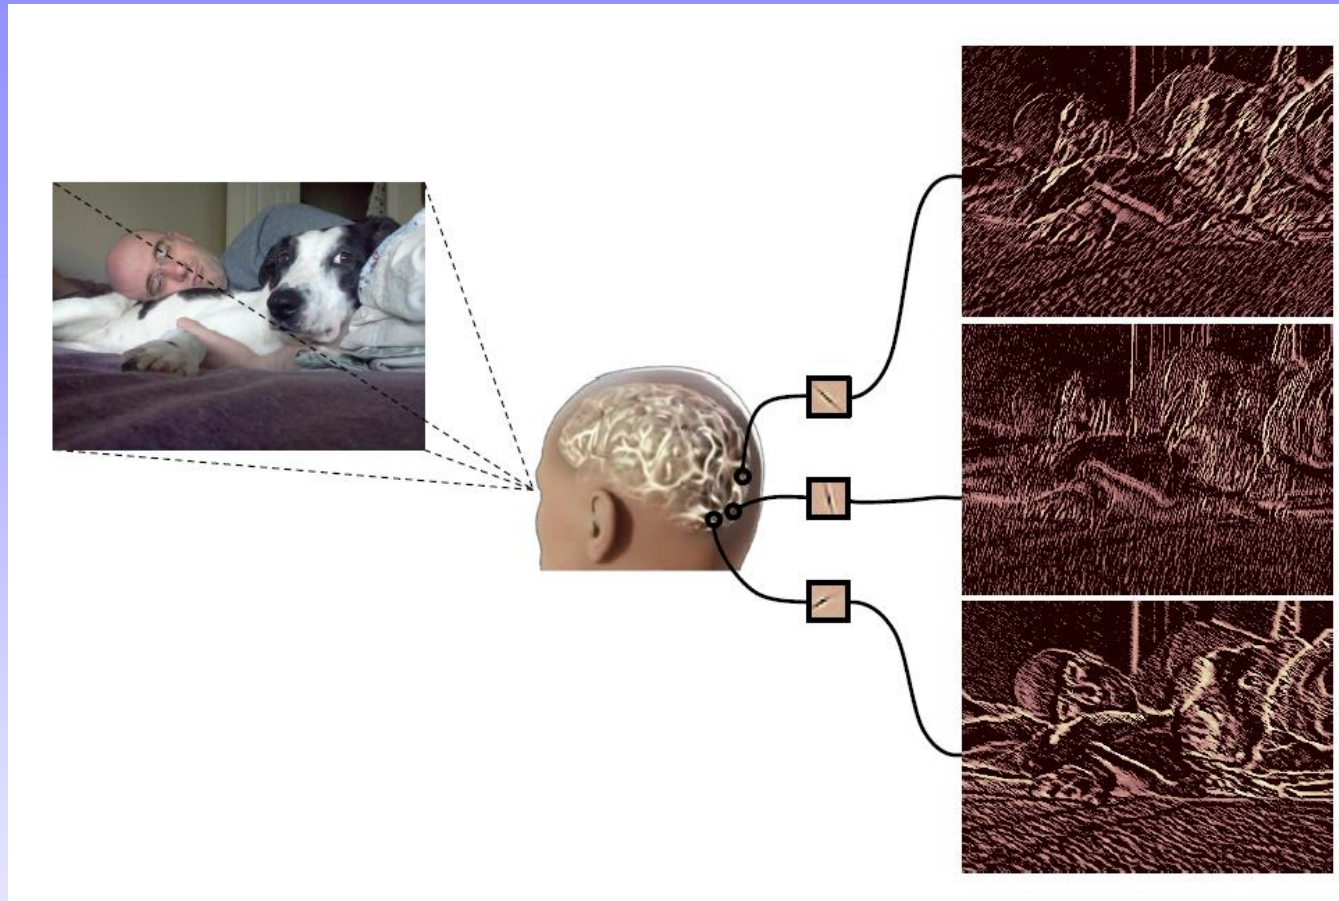
דוגמא: תכן תכונות עבור זיהוי עצמים ויזואליים



יוצרי South park

- קיים ידע חלקי בלבד על התהליכים היוצרים את הנתונים של עצמים בתמונה, וכן על התהליכים העומדים מאחורי התפיסה הויזואלית של עצמים.
- אחת העובדות החשובות לזיהוי עצמים – עצמים בתמונה (יער, אנשים, נוף עיר, חיות או חדר בתוך בית – לכולם יש מספר קטן יחסית של **קצוות (edges)** המאפיינים אותם ומבחינים בין אובייקטים
- בתמונה למעלה, רק על-פי ה- edges אפשר לדעת מה התמונה מכילה, למרות שרוב הפיקסלים לא מתארים את הקצוות.

Feature design for visual object detection

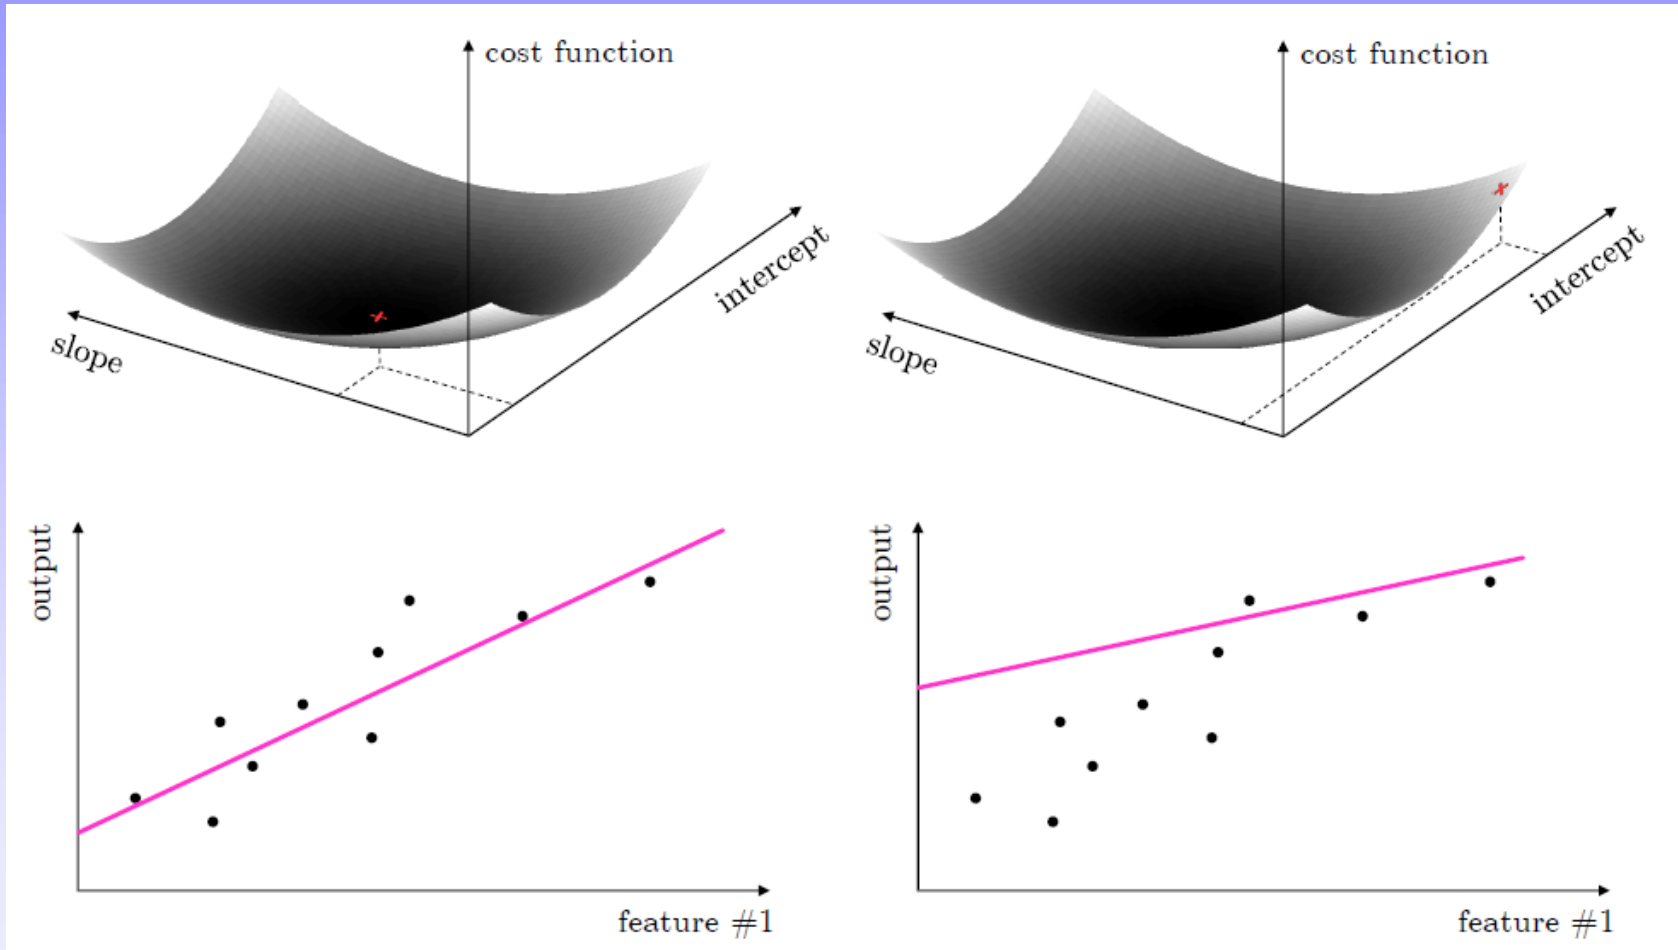


- הנורונים מהווים יחידות לזיהוי קצוות
- כל נורון פועל כמזהה קצוות (edge detector) קטן, וממקם את הקצוות בתמונה באוריינטציה ועובי יחודיים
- הטענה היא כי אנשים ויונקים "רואים" על-ידי צירוף ועיבוד של edge detected images

אופטימיזציה נומרית

- ניסוח החיפוש של הפרמטרים עבור מודל הלמידה נעשה דרך פונקציות מתימטיות מוגדרות היטב.
- פונקציות אלה מכונות בדרך כלל בשם **פונקציות עלות** (cost functions), מקבלות קבוצה של פרמטרים ומחזירות ציון המצביע את מידת השגת משימת הלימוד הנתונה.
- ערך גבוה המוחזר על-ידי הפונקציה – בחירת הפרמטרים תשיג תוצאה גרועה.
- בחירת פרמטרים המשיגה תוצאה נמוכה של הציון (של פונקציית העלות) – מצביעה על תוצאה גבוהה.
- לדוגמא: עבור חיזוי ערך המניה – התאמת ישר הרגרסיה נעשית על-ידי כוונן של שני פרמטרים – שיפוע הישר והחיתוך עם ציר ה- y (intercept).
- באופן גאומטרי – מתאים למציאת קבוצת הפרמטרים המביאה למינימום את פונקציית העלות הדו-ממדית כפי שאפשר לראות באיור הבא:

אופטימיזציה נומרית - רגרסיה



אופטימיזציה נומרית - סווג

- גם עבור בעיית הדוגמא (toy problem) של הבחנה בין תמונות כלבים לחתולים המטרה הייתה למצוא ישר מפריד – מציאת שני פרמטרים (שיפוע, נקודת חיתוך).



- מציאת הפרמטרים האידיאליים יביאו לפונקציית עלות מינימלית.
- עבור שני המקרים של רגרסיה וסווג, מאחר וערך נמוך של פונקציית העלות מתאים למודל מוצלח (תפקוד גבוה) – נחפש למזער פונקציות עלות כדי למצוא פרמטרים אידיאליים למודלי הלמידה הקשורים.
- שימוש בכלים של אופטימיזציה נומרית.

אופטימיזציה נומרית - סווג

