
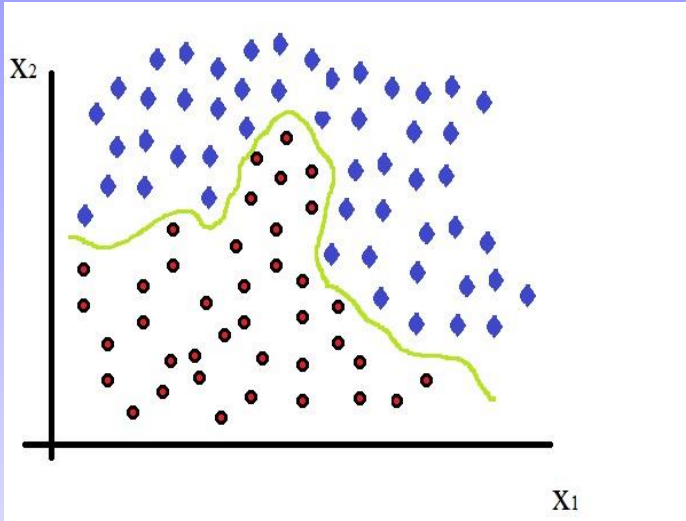


# ANN



# היפותזות לא ליניאריות

- רשתות עצביות – משמשות במערכות רבות של למידה חישובית.
- סוג לא ליניארי.
- נתבונן בדוגמא הבאה:



- אפשר להשתמש ברגרסיה לוגיסטית, באמצעות פולינום עם מספיק איברים כמו:

$$h_{\theta}(x) = g\left(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1^2 x_2 + \theta_6 x_1^2 x_2^2 + \theta_7 x_1^2 x_2^3 + \theta_8 x_1^3 x_2^2\right)$$

- פתרון כזה יוצר את משטח ההפרדה (---).
- מתאים לוקטור תכונות **דו-מימדי**.

# היפותזות לא ליניאריות

- בבעיות למידה רבות מספר רב של תכונות – הפתרון הקודם לא מתאים.
- לדוגמא –
- בבעיית הבתים עליה דיברנו, נניח שזוהי בעיית סווג – וצריך לסווג את הבתים כבעלי פוטנציאל גבוה או נמוך למכירה –
- תכונות רבות –
- גודל הבית,
- מספר חדרי השינה,
- מספר מפלסים,
- שטח הגינה,
- גיל הבית,
- מקומות חנייה וכו'.



# היפותזות לא ליניאריות

- בבעיית גילוי ה-spam – (או באופן כללי בבעיית זיהוי טקסט) וקטור התכונות עשוי להכיל מילון של 10000-50000 מלים.

AARDVARK  
AARDWOLF AARON  
ABACK ABACUS  
ABAF ABALONE  
ABANDON  
ABANDONED  
ABANDONMENT  
ABANDONS ABASE  
ABASED  
ABASEMENT ABASH  
ABASHED ABATE  
ABATED  
ABATEMENT  
ABATES ABATTOIR  
ABATTOIRS ABBE  
ABBESS ABBEY  
ABBEYS ABBOT  
ABBOTS  
ABBREVIATE  
ABBREVIATED  
ABBREVIATES  
ABBREVIATING  
ABBREVIATION  
ABBREVIATIONS  
ABDICATE  
ABDICATED



# היפותזות לא ליניאריות

- עבור 100 תכונות –  
אם ננסה לכלול את כל התכונות הקוודרטיות בלבד –  
כלומר:

$$x_1^2, x_1x_2, x_1x_3, \dots, x_1x_{100}, \dots, x_1^2, x_2x_3, \dots, x_{100}^2$$

$$\approx o(n^2) \quad , \quad \approx n^2 / 2 = 5000 \text{ features}$$

## היפותזות לא ליניאריות

- אפשר לכלול רק תת-קבוצה של התכונות המוצעות, לדוגמא:


$$x_1^2, x_2^2, \dots, x_{100}^2$$

- התאמת משטחי הפרדה כמו אליפסות, אך לא משטחים יותר מורכבים הדרושים לביצוע מוצלח של הסוג.
  - הכללת פרמטרים מדרגה שלישית: עבור  $n=100$  תכונות מקוריות מספר התכונות עשוי לעלות על 150,000.
- $$\approx o(n^3) \quad , \quad \approx 170,000 \text{ features}$$
- יותר מדי תכונות: 1. התאמת יתר 2. חישוביות

האם יש דרך מוצלחת יותר לבנות מסווג לא ליניארי?



# ייצוג המודלים ברשתות עצביות




תיאור של נוירון בודד:  
מבנה של נוירון אופייני.

- ניתן להבחין במרכיבים הבאים:
- 1. דנדריטים: "ערוצי כניסה" מנוירונים אחרים **Dendrites**
- 2. גוף התא: המרכיב ה"חישובי" **Soma**
- 3. אקסונים וחיבורים סינפטיים: ערוצי היציאה לנוירונים אחרים **(Axons)**



# מודל של תא עצב (נוירון) בודד

*bias unit*  $x_0 = 1$



- מודל של נוירון – מימוש פשטני:


$$x = \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}, \quad \theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix}$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

# מודל של תא עצב (נוירון) בודד

*bias unit*  $x_0 = 1$



- למעשה זוהי **יחידה לוגיסטית**

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

- **פונקציית האקטיבציה** היא פונקציה **סיגמואידית**


$$g(z) = \frac{1}{1 + e^{-z}}$$

- הפרמטרים נקראים לעתים **משקלות**.


# רשת עצבית

רשת עצבית :

חיבור של מספר נוירונים או יחידות



# רשת עצבית




עבור הרשת הנ"ל נשתמש בסימונים הבאים:

- האקטיבציה של הנוירון ה- $i$  בשכבה ה- $j$  –  $a_i^{(j)}$
- מטריצת משקלות (או פרמטרים השולטים על המיפוי) –  $\theta^{(j)}$  (מהשכבה ה- $j$  לשכבה ה- $j+1$ )

**לדוגמא:** האקטיבציה של הנוירון הראשון בשכבה השניה (ה-**hidden layer**) –  $a_1^{(2)}$


# רשת עצבית סימון המשקלות (weights)



לדוגמא: סימון המשקל מהנוירון ה-  $i$  בשכבה ה-  $j$  לנוירון ה-  $k$  בשכבה ה-  $j+1$ :  $\theta_{ki}^{(j)}$

$a_i^{(j)}$   $\rightarrow$   $a_k^{(j+1)}$

## רשת עצבית




נציג את החישובים שמתבצעים ברשת:

$$a_1^{(2)} = g\left(\theta_{10}^{(1)}x_0 + \theta_{11}^{(1)}x_1 + \theta_{12}^{(1)}x_2 + \theta_{13}^{(1)}x_3\right)$$

$$a_2^{(2)} = g\left(\theta_{20}^{(1)}x_0 + \theta_{21}^{(1)}x_1 + \theta_{22}^{(1)}x_2 + \theta_{23}^{(1)}x_3\right)$$

$$a_3^{(2)} = g\left(\theta_{30}^{(1)}x_0 + \theta_{31}^{(1)}x_1 + \theta_{32}^{(1)}x_2 + \theta_{33}^{(1)}x_3\right)$$

## רשת עצבית




שכבת היציאה (מכילה במקרה זה נוירון אחד):

$$h_\theta(x) = a_1^{(3)} = g\left(\theta_{10}^{(2)}a_0^{(2)} + \theta_{11}^{(2)}a_1^{(2)} + \theta_{12}^{(2)}a_2^{(2)} + \theta_{13}^{(2)}a_3^{(2)}\right)$$

הרשת מכילה 3 יחידות כניסה ו-3 יחידות חבויים ולכן:

$$\Theta^{(1)} \in R^{3 \times 4}$$


## רשת עצבית



באופן כללי, אם לרשת  $S_j$  יחידות בשכבה ה-  $j$  ו-  $S_{j+1}$  יחידות בשכבה  $j+1$  אז מטריצת המשקלות תהיה מטריצה עם:  $S_{j+1} \times S_j + 1$  מימדים.



# מימוש מטריצי - וקטורי



$$a_1^{(2)} = g \left( \theta_{10}^{(1)} x_0 + \theta_{11}^{(1)} x_1 + \theta_{12}^{(1)} x_2 + \theta_{13}^{(1)} x_3 \right)$$

$$a_2^{(2)} = g \left( \theta_{20}^{(1)} x_0 + \theta_{21}^{(1)} x_1 + \theta_{22}^{(1)} x_2 + \theta_{23}^{(1)} x_3 \right)$$

$$a_3^{(2)} = g \left( \theta_{30}^{(1)} x_0 + \theta_{31}^{(1)} x_1 + \theta_{32}^{(1)} x_2 + \theta_{33}^{(1)} x_3 \right)$$


נסמן:

$$z_1^{(2)} = \theta_{10}^{(1)} x_0 + \theta_{11}^{(1)} x_1 + \theta_{12}^{(1)} x_2 + \theta_{13}^{(1)} x_3$$

$$z_2^{(2)} = \theta_{20}^{(1)} x_0 + \theta_{21}^{(1)} x_1 + \theta_{22}^{(1)} x_2 + \theta_{23}^{(1)} x_3$$

$$17 \quad z_3^{(2)} = \theta_{30}^{(1)} x_0 + \theta_{31}^{(1)} x_1 + \theta_{32}^{(1)} x_2 + \theta_{33}^{(1)} x_3$$

# מימוש מטריצי - וקטורי Forward Propagation



$$a_1^{(2)} = g\left(z_1^{(2)}\right)$$

$$a_2^{(2)} = g\left(z_2^{(2)}\right)$$

$$a_3^{(2)} = g\left(z_3^{(2)}\right)$$


$$z_i^{(j)}$$

כל אחד מה-  $z_i$  הוא קלט **לנוירון ה-  $i$**   
**בשכבה ה-  $j$** , ובמקרה זה לשכבה 2

כאשר :

# מימוש מטריצי - וקטורי Forward Propagation

נגדיר באופן מטריצי:



$$x = \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}, \quad z^{(2)} = \begin{pmatrix} z_1^{(2)} \\ z_2^{(2)} \\ z_3^{(2)} \end{pmatrix}$$

$$z^{(2)} = \Theta^{(1)} x = \begin{pmatrix} \theta_{10}^{(1)} & \theta_{11}^{(1)} & \theta_{12}^{(1)} & \theta_{13}^{(1)} \\ \theta_{20}^{(1)} & \theta_{21}^{(1)} & \theta_{22}^{(1)} & \theta_{23}^{(1)} \\ \theta_{30}^{(1)} & \theta_{31}^{(1)} & \theta_{32}^{(1)} & \theta_{33}^{(1)} \end{pmatrix} \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}$$


$$a_2^{(2)} = g(z_2^{(2)}) \in \mathbf{R}^3$$

כאשר הפונקציה  $g$  פועלת על האלמנטים של  $z$  (כל אחד לחוד באמצעות הסיגמואיד)

# מימוש מטריצי - וקטורי Forward Propagation

מטעמי עקביות אפשר לסמן את שכבת הכניסה  $a^{(1)}$ , כלומר  $x=a^{(1)}$  ולכן:

$$z^{(2)} = \Theta^{(1)} a^{(1)}$$



נוסיף לשכבה החבויה את:  $a_0^{(2)} = 1$


$$z^{(3)} = \Theta^{(2)} a^{(2)}$$

$$a^{(2)} = \begin{pmatrix} a_0^{(2)} \\ a_1^{(2)} \\ a_2^{(2)} \\ a_3^{(2)} \end{pmatrix} \quad \text{כאשר:}$$

# מימוש מטריצי - וקטורי Forward Propagation

$$h_{\theta}(x) = a_1^{(3)} = g\left(z^{(3)}\right) \quad \text{והיציאה של הרשת היא אם כן:}$$

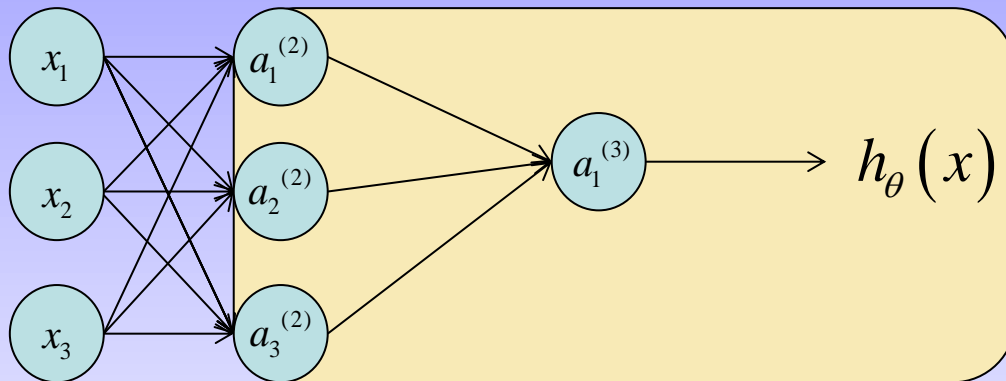
$$z^{(3)} = \Theta^{(2)} a^{(2)} \quad \text{כאשר:}$$



# Forward Propagation

ה- Forward Propagation עוזר להבין מה הרשת מבצעת, ואיך היא מאפשרת ליצור היפותיזות לא ליניאריות

נתבונן בחלק השמאלי של הרשת בלבד




מה שהרשת מבצעת כאן זהה לרגרסיה לוגיסטית:

$$h_{\theta}(x) = a_1^{(3)} = g\left(z^{(3)}\right) = g\left(\Theta_{10}^{(2)}a_0^{(2)} + \Theta_{11}^{(2)}a_1^{(2)} + \Theta_{12}^{(2)}a_2^{(2)} + \Theta_{13}^{(2)}a_3^{(2)}\right)$$


# תצורות רשת נוספות

אפשר לבנות רשת בתצורות שונות:



# תצורות רשת נוספות




## רשתות אלה נקראות Feedforward Networks





# דוגמא לעבודת הרשת על קלט לא ליניארי


כיצד רשת עצבית עובדת על קלט מורכב לא ליניארי, וכיצד רשת יכולה ללמוד היפותיזות לא ליניאריות מורכבות?



זוהי דוגמא פשוטה של ה-data משמאל


# אלגוריתם הלימוד להתאמת פרמטרים

- נדבר עתה על פונקציית המחיר.
- נסמן את הרשת הבאה:



שכבה 1      שכבה 2      שכבה 3      שכבה 4  
Input layer   Hidden layer   Hidden layer   Output layer

# אלגוריתם הלימוד להתאמת פרמטרים




נניח שנתונות דוגמאות האימון הבאות:

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$$



# אלגוריתם הלימוד להתאמת פרמטרים



נסמן ב-  $L$  – סה"כ השכבות ברשת. במקרה הזה  $L=4$   
נסמן ב-  $s_l$  – מספר היחידות (ללא ה-Bias) בשכבה ה-  $l$   
לדוגמא:  $s_1 = 3, s_2 = 5, s_4 = s_L = 1$


במקרה של סוג בינארי דרושה יחידת פלט אחת, והתיוג  
הוא  $y = 0 \text{ or } y = 1$

$$h_{\Theta}(x) \in R$$

$$S_L = 1$$

# סוג רב מחלקתי Multiclass classification

כאשר הסוג הוא ל-  $k$  מחלקות, לדוגמא – סוג ל-  $k=4$  מחלקות



$$y \in R^k, \quad y = \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} \right\}$$


לדוגמא – מצב מזג האוויר:

שמש, מעונן, גשום, מושלג

(סה"כ צריך  $k$  יחידות פלט)

$$h_{\Theta}(x) \in R^4$$

$$S_L = 4$$




## פונקציית המחיר עבור רשת עצבית

פונקציית המחיר עבור הרגרסיה הלוגיסטית:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) + \underbrace{\frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2}_{\text{(איבר הרגולריזציה)}} \\ \text{(ללא } \theta_0 \text{)}$$

עבור רשת עצבית נבצע הכללה של פונקציית המחיר.



## פונקציית המחיר עבור רשת עצבית

- עבור רשת עצבית נבצע הכללה של פונקציית המחיר:

$$h_{\Theta}(x) \in R^K \quad (h_{\Theta}(x))_i = i^{th} \text{ output}$$

$$J(\theta) = -\frac{1}{m} \left( \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log((h_{\theta}(x^{(i)}))_k) + (1 - y_k^{(i)}) \log(1 - h_{\theta}(x^{(i)})_k) \right)$$


$$+ \frac{\lambda}{2m} \sum_{l=1}^{L-1} \sum_{i=1}^{S_l} \sum_{j=1}^n (\Theta_{ji}^l)^2$$

איבר הרגולריזציה

עבור כל יחידות הפלט

עבור כל הדוגמאות

בהמשך נבצע אופטימיזציה עבור פונקציית המחיר הנ"ל



## אלגוריתם ה- Backpropagation

נדבר על אלגוריתם למיזעור פונקציית המחיר:  $\min_{\Theta} J(\Theta)$

כדי למזער את פונקציית המחיר נצטרך לחשב את:  $J(\Theta)$

$$\frac{\partial}{\partial \Theta_{ij}^l} J(\Theta), \quad \Theta_{ij}^l \in R$$

איך נחשב את הנגזרת החלקית לפי  $\Theta_{ij}^l$  ?

